

ΤΗΛ 417: Θεωρία Πληροφορίας και Κωδικοποίηση

Εαρινό Εξάμηνο 2025

Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Πολυτεχνείο Κρήτης

Εργασία 2

29 Απριλίου 2025

Διδάσκων: Γεώργιος Καρυστινός

Αριθμός Ομάδας Εργασίας: 30

Επώνυμο: Μαλαμάς

Όνομα: Νικόλαος

ΑΜ: 2020030180

Επώνυμο: Πατσέα

Όνομα: Ιωάννα - Γεωργία

ΑΜ: 2020030033

1.


1.

Η εντροπία της ΤΜ X βρίσκεται ως:

$$H(X) = - \sum_i p_X(x_i) \log_2 p_X(x_i) = - \left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{8} \log_2 \frac{1}{8} + \frac{1}{8} \log_2 \frac{1}{8} \right) = 1.75 \text{ bits/symb}$$

2.

Δεδομένης της κατανομής που δίνεται δημιουργούμε το παρακάτω δέντρο Huffman.



Υπογραμμίζουμε ότι τα σύμβολα 3 και 4 έχουν την ίδια πιθανότητα, και έτσι δεν έχει σημασία σε ποιον από τους δύο κλάδους θα ανάθεσουμε το 0 και σε ποιον το 1. Επομένως, είμαστε συνεπείς σχετικά με την επιλογή των 'Huffman flags' και η κωδικοποίησή μας είναι ορθή.

4.

Η ορθότητα του κώδικα που αναπτύξαμε στα προηγούμενα ερωτήματα επαληθεύεται καθότι στην κονσόλα εκτυπώνονται τα εξής:

Command Window

The recovered symbols, indeed match the initial ones!

Αποθηκεύοντας κάθε bit stream που προκύπτει μετά απο κάθε Monte Carlo πείραμα, είμαστε σε θέση να βρούμε το μέσο μήκος κωδικής λέξης ανα stream κάθε πειράματος και έτσι τελικά παίρνοντας τον μέσο όρο πάνω σε όλα τα πειράματα να υπολογίσουμε το μέσο μήκος κωδικοποιημένης προς αποκωδικοποιημένη λέξη.

Κατά την εκτέλεση του αντίστοιχου MATLAB κώδικα παίρνουμε στην κονσόλα τα εξής:

Command Window

Comparing the numerical average of encoded word length with the entropy of the source

Numerical average: 1.7504 bits/symb

Source Entropy: 1.7500 bits/symb

Παρατηρούμε ότι το μέσο μήκος κωδικοποιημένης (κατά Huffman) λέξης προσεγγίζει πολύ κοντά την εντροπία της πηγής X και αυτό γιατί ο κώδικας Huffman είναι στιγμιαίος και

επομένως απο το αντίστοιχο θεώρημα ισχύει για το μέσο μήκος κωδικής λέξης $L(C)$ ισχύει:

$$L(C) \geq H_D(X)$$

Εδώ η (σχεδόν) ισότητα επιτυγχάνεται διότι οι πιθανότητες συμβόλων που παράγει η πηγή είναι αρνητικές δυνάμεις της D -αδικής εντροπίας, με $D = 2$.

5.

Περνώντας απο τις θέσεις 5 και 6 κάθε bit stream μετράμε και αποθηκεύουμε τις εμφανίσεις των 0 και 1 και τις εκτυπώνουμε στην κονσόλα του MATLAB λαμβάνοντας τα εξής:

Command Window

By counting the #of appearances of each bit we can obtain their distribution:

#(d_5 = 0): 503 - #(d_5 = 1): 497

#(d_6 = 0): 477 - #(d_6 = 1): 523

#[(d_5,d_6) = 00]: 241

#[(d_5,d_6) = 01]: 236

#[(d_5,d_6) = 10]: 262

#[(d_5,d_6) = 11]: 261

Παρόλο που τα παραπάνω νούμερα δεν είναι σταθερά για κάθε πείραμα, είναι ενδεικτικά της κατανομής που ακολουθούνε τόσο τα d_5, d_6 ξεχωριστά όσο και κατά ζευγάρια (d_5, d_6) , κάτι το οποίο γίνεται εύκολα αντιληπτό εκτελώντας πολλές φορές τον κώδικα.

Έτσι, συνολικά, μπορούμε να πούμε ότι αφού οι εμφανίσεις των 0 και 1 είναι περίπου 500 τόσο στην κατανομή του d_5 , όσο και στην κατανομή του d_6 , αυτά ακολουθούν την ομοιόμορφη κατανομή.

Παράλληλα όσο αφορά τα ζευγάρια (d_5, d_6) , εύκολα παρατηρείται ότι κάθε 2-bit συνδυασμός των d_5, d_6 εμφανίζεται περίπου 250 φορές υποδεικνύοντας ότι και τα ζευγάρια (d_5, d_6) ακολουθούν την ομοιόμορφη κατανομή.

Η παραπάνω παρατήρηση είναι αναμενόμενη καθώς τα d_5 και d_6 έχουν παραχθεί ανεξάρτητα μεταξύ τους και ακολουθούν και τα δύο την ομοιόμορφη κατανομή. Επομένως, η απο-κοινού κατανομή τους θα είναι και αυτή ομοιόμορφη και ίση με το γινόμενο των δύο επιμέρους κατανομών.

2.

1.

Αξιοποιώντας την συνάρτηση *'eig()'* του MATLAB λαμβάνουμε τα ιδιοδιανύσματα του πίνακα μετάβασης Π και επικεντρωνόμαστε σε αυτό που αντιστοιχεί σε ιδιοτιμή $\lambda = 1$. Αφού το κανονικοποιήσουμε λαμβάνουμε την κατανομή σύγκλισης p_{X_∞} . Στην συνέχεια, η εντροπία της κατανομής σύγκλισης βρίσκεται εύκολα μέσω του γνωστού τύπου $H(X) = -\sum_i p_X(x_i) \log_2 p_X(x_i)$, ενώ ο ρυθμός εντροπίας βρίσκεται ως το εσωτερικό γινόμενο της εντροπίας κάθε στήλης του πίνακα μετάβασης επί το διάνυσμα κατανομής σύγκλισης. Όλες οι παραπάνω πράξεις είναι υλοποιημένες σε MATLAB.


2.

Για την προσομοίωση της αλυσίδας Markov που περιγράφεται στην εκφώνηση υλοποιήθηκε η συνάρτηση *'simulate_MC()'*. Ως αρχική κατανομή τέθηκε η

$$p_{X_0} = \begin{bmatrix} 0.1 \\ 0.25 \\ 0.35 \\ 0.15 \\ 0.15 \end{bmatrix}$$


3.

α) Για την κατανομή σύγκλισης δημιουργούμε το παρακάτω δέντρο Huffman και βάσει αυτού υλοποιούμε τις συναρτήσεις κωδικοποίησης και αποκωδικοποίησης, *'Huffman_encoding2a()'* και *'Huffman_decoding2a()'*




β) Για τις δεσμευμένες κατανομές, παίρνουμε κάθε σειρά του πίνακα μετάβασης, και δημιουργούμε το παρακάτω δέντρο Huffman και βάσει αυτού υλοποιούμε τις συναρτήσεις κωδικοποίησης και αποκωδικοποίησης, *'Huffman_encoding2b_n()'* και *'Huffman_decoding2b_n()'*, με $n = \{1, 2, 3, 4, 5\}$ για τον αριθμό της γραμμής του πίνακα μετάβασης.


$PX|X_{n-1}=1$




$PX|X_{n-1}=2$




$PX|X_{n-1}=3$



$PX|X_{n-1}=4$



$P_{X|X_{n-1}=5}$



4.

Προς επιβεβαίωση του αν λάβαμε τα αρχικά σύμβολα στην περίπτωση της κατανομής σύγκλισης και κάθε δεσμευμένης κατανομής, εκτυπώνουμε τον έλεγχο στην κονσόλα, μαζί με το μέσο μήκος κωδικοποιημένης προς αποκωδικοποιημένης λέξης, την εντροπία της πηγής και το ρυθμό εντροπίας:

Command Window

2.4(a):

-The recovered symbols, indeed match the initial ones!

-Comparing the numerical average of the encoded word average length with the entropy of the source

Numerical average: 2.4411 bits/symb

Source Entropy: 2.3219 bits/symb

Entropy Rate: 1.8750 bits/symb

2.4(b1):

-The recovered symbols, indeed match the initial ones!

-Comparing the numerical average of the encoded word average length with the entropy of the source

Numerical average: 2.6008 bits/symb

Source Entropy: 2.3219 bits/symb

Entropy Rate: 1.8750 bits/symb

2.4(b2):

-The recovered symbols, indeed match the initial ones!

-Comparing the numerical average of the encoded word average length with the entropy of the source

Numerical average: 3.1604 bits/symb

Source Entropy: 2.3219 bits/symb

Entropy Rate: 1.8750 bits/symb

2.4(b3):

-The recovered symbols, indeed match the initial ones!

-Comparing the numerical average of the encoded word average length with the entropy of the source

Numerical average: 2.6052 bits/symb

Source Entropy: 2.3219 bits/symb

Entropy Rate: 1.8750 bits/symb

Command Window

2.4(b4):

-The recovered symbols, indeed match the initial ones!

-Comparing the numerical average of the encoded word average length with the entropy of the source

Numerical average: 2.6366 bits/symb

Source Entropy: 2.3219 bits/symb

Entropy Rate: 1.8750 bits/symb

2.4(b5):

-The recovered symbols, indeed match the initial ones!

-Comparing the numerical average of the encoded word average length with the entropy of the source

Numerical average: 2.3171 bits/symb

Source Entropy: 2.3219 bits/symb

Entropy Rate: 1.8750 bits/symb

ΣΗΜΕΙΩΣΗ: Δυστυχώς για την υλοποίηση του 2.3β και 2.4β δεν καταφέραμε να συμπύξουμε όλη την λύση σε μια μόνο συνάρτηση, με αποτέλεσμα να χρειαστεί να υλοποιηθούν πολλές διαφορετικές συναρτήσεις για ουσιαστικά την ίδια δουλειά, χωρίς αυτό να επηρεάζει την λειτουργικότητα της λύσης μας.

3.

Για την επίλυση της συγκεκριμένης άσκησης υλοποιήθηκαν όλες οι ζητούμενες συναρτήσεις από το ερώτημα 1 έως το ερώτημα 5, ενώ στο βήμα 6 αξιοποιήθηκε το αρχείο `original_data_5.bin` για να λάβουμε τα αποτελέσματα που αναλύονται παρακάτω.


Συνοπτικά, τρέχοντας ένα `for-loop` πάνω σε τιμές 1 έως 10 για το n , κωδικοποιούμε τα δεδομένα του παραπάνω αρχείου σε n -άδες αξιοποιώντας τους κώδικες Huffman και Shannon-Fano και αποθηκεύουμε την συμπιεσμένη εκδοχή του αρχείου (διανύσματα Y) με σκοπό τελικά να τα πλοτάρουμε.

Είναι σημαντικό να σημειωθεί ότι το μέγεθος του αρχείου $M = 3628800$ bits είναι πολλαπλάσιο όλων των τιμών του n από 1 έως 10 και έτσι στον κώδικά μας δεν χρειάστηκε να προνοήσουμε για περιπτώσεις που bits στο τέλος του διανύσματος X θα παρέμεναν αναποκωδικοποιήτα, απλοποιώντας έτσι κατά πολύ την άσκηση.

7.

Αναφορικά με τον κώδικα Huffman, μπορεί κανείς εύκολα να δει ότι όσο το n μεγαλώνει, το μέγεθος του συμπιεσμένου bit stream Y προσεγγίζει την εντροπία σε σημείο που φαινομενικά ταυτίζεται με αυτήν. Αυτό συμβαίνει διότι γνωρίζουμε από την θεωρία ότι κωδικοποιώντας το αλφάβητο μιας πηγής X σε blocks n -άδων, ο κώδικας Huffman μας δίνει την δυνατότητα να μειώσουμε το μέσο μήκος κωδικής λέξης ανά σύμβολο έτσι ώστε να προσεγγίσουμε την εντροπία σε ότι βαθμό ακρίβειας επιθυμούμε επιλέγοντας επαρκώς μεγάλο n .

Αντίθετα, παρατηρούμε ότι για την περίπτωση της block κωδικοποίησης κατά Shannon-Fano, παρότι αυτή παρουσιάζει την ίδια εκθετικά μειούμενη συμπεριφορά με την block κωδικοποίηση Huffman, η πρώτη δεν προσεγγίζει το ίδιο στενά την εντροπία της πηγής με την τελευταία. Το παραπάνω είναι λογικό μιας και η θεωρία μας υποδεικνύει ότι $H(X) + 1 \leq L(C_{SFE}) < H(X) + 2$, πράγμα που δικαιολογεί την 'χαλαρή' προσέγγιση τόσο του πάνω όσο και του κάτω ορίου στην γραφική παράσταση.




Σχήμα 1: Τα μεγέθη των compressed αρχείων κατά block Huffman (κόκκινο) και block Shanon-Fano (μπλε), συνάρτησε του μεγέθους block n

8.

Παρατηρούμε ότι η κατανομή των 0 και 1 στο αρχικό bit stream που παράγονται από την ΤΜ X έχει σαφή προτίμηση στα 0, μιας και έχουμε ορίσει την πιθανότητα του συμβόλου 1 ίση με $p = 0.1$. Αυτό ωστόσο δεν φαίνεται να ισχύει για τα bit streams που παράγονται από τις ΤΜ Y_{SF} και Y_{Huf} , και αυτό γιατί οι κώδικες Huffman και Shannon-Fano αντίστοιχα αξιοποιούν τα 0 και 1 χωρίς να βασίζονται στις πιθανότητες των συμβόλων.

Πιο συγκεκριμένα, ο Huffman χρησιμοποιεί τα 0 και 1 σαν flags που υποδυκνείουν 'μεγαλύτερη-μικρότερη' πιθανότητα, μεταξύ των δύο συμβόλων με την τρέχουσα μικρότερη πιθανότητα, ενώ ο κώδικας Shannon-Fano τα αξιοποιεί για το διαχωρισμό των συμβόλων σε 'πάνω-κάτω' ομάδες. Καταλαβαίνουμε λοιπόν, ότι η πιθανότητα των συμβόλων 0 και 1, αφήνει ανεπηρεάστο τον τρόπο με τον οποίο ο κάθε κώδικας θα κατανέμει τα 0 και 1 στις κωδικοποιημένες λέξεις.

Με άλλα λόγια οι δύο κώδικες κάνουν (περίπου) 'δίκαιη' χρήση των 0 και 1, για αυτό και οι αντίστοιχες πιθανότητες τους (στο παρακάτω διάγραμμα) είναι προσεγγιστικά 0.5 για το κάθε ένα.



Σχήμα 2: Δειγματικές PMF της ΤΜ X και των ΤΜ Y_{SF} και Y_{Huf} , για $n = 10$